

# Spark 2.0: What's Next

Reynold Xin @rxin  
Spark Conference Japan  
Feb 8, 2016



Please put up your hand

if you know what Spark is?



# Put up your hand

if you think your significant other  
know what Spark is?

(girlfriend, boyfriend, wife, husband, ...)



# This Talk

What is Spark?

How are people using it?

Spark 2.0



open source data processing engine built around  
speed, ease of use, and sophisticated analytics

スピード、使いやすさ、洗練された分析を兼ね合わせた  
オープンソースのデータ処理エンジン

Spark SQL +  
DataFrames

Streaming

MLlib  
*Machine Learning*

GraphX  
*Graph Computation*

Spark Core API

R

SQL

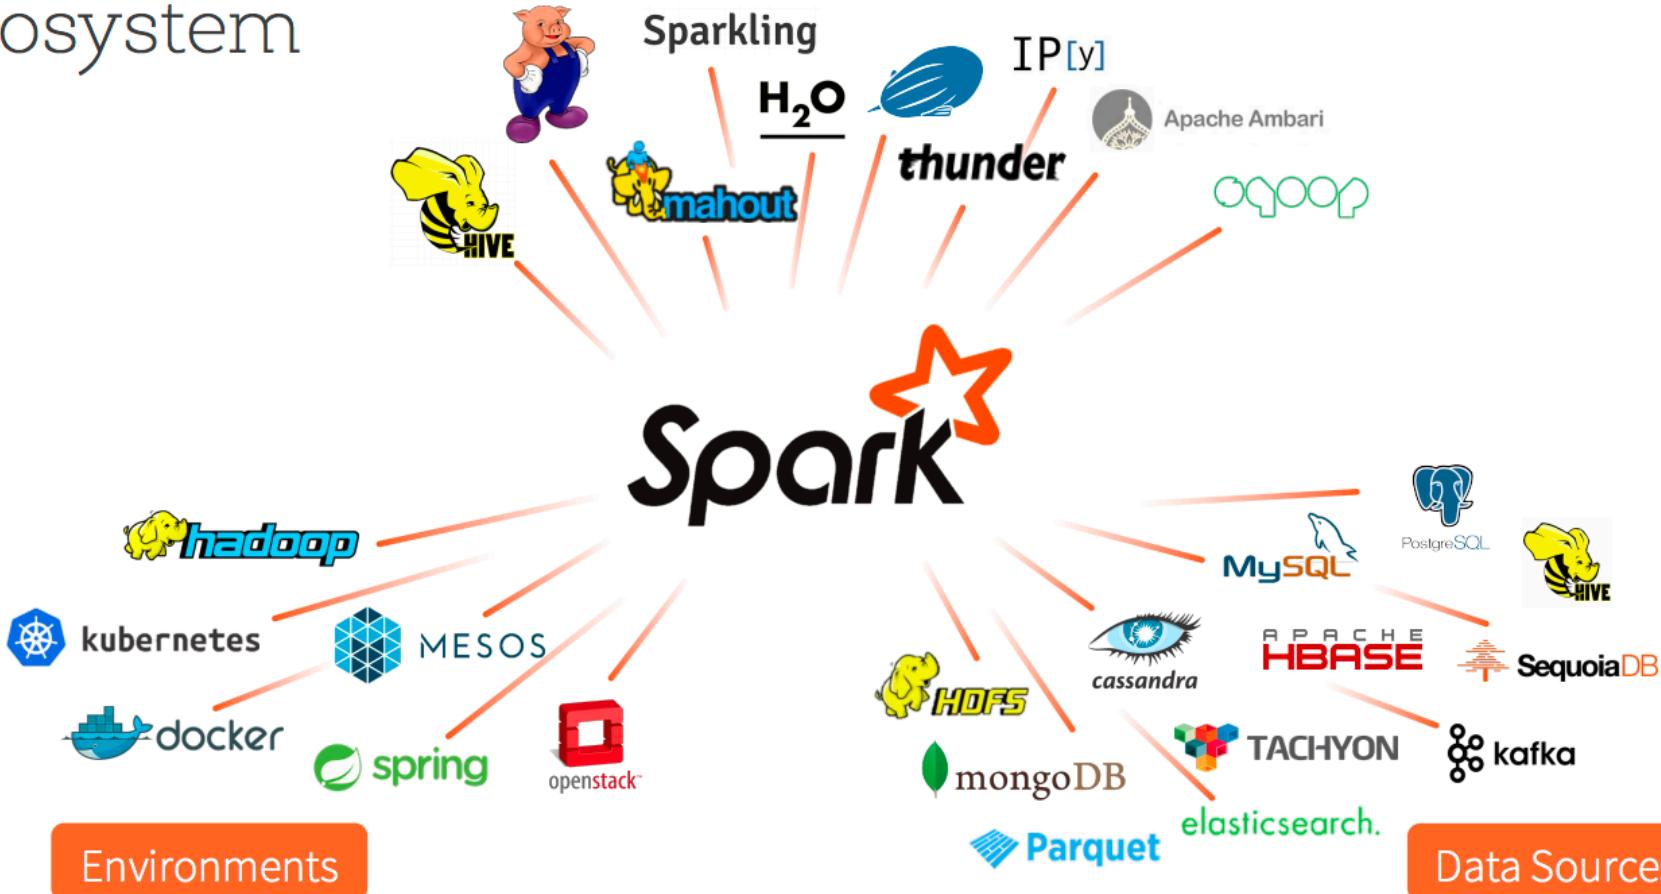
Python

Scala

Java

# Open Source Ecosystem

Applications



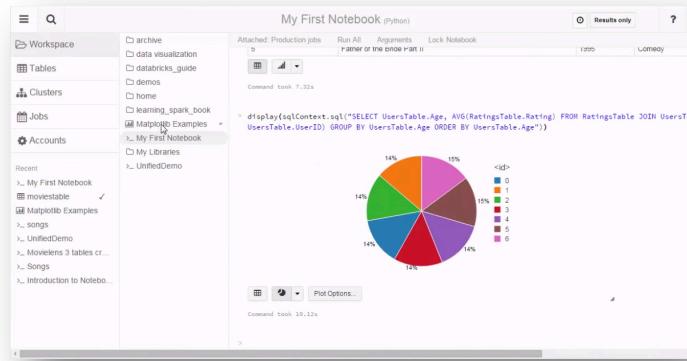
# About Databricks Databricks について

Founded by creators of Spark & behind Spark development  
Spark開発者とSpark開発を支持する人たちによって設立された  
Cloud Enterprise Spark Platform

- Cluster management, interactive notebooks, dashboards, production jobs, data governance, security, ...

## エンタープライズクラウド Spark プラットフォーム

- クラスタ管理、対話型ノートブック
- ダッシュボード、ジョブ生成
- データガバナンス、セキュリティ



# 2015: Great Year for Spark 2015: Sparkにとって大きな年

Most active open source project in data (1000+ contributors)

データ上、最も活発なオープンソースプロジェクト (1000人以上の貢献者)

New language: R

新しい言語 : R

Widespread industry support & adoption

幅広い業界サポートと採用

# Meetup Groups: December 2014



# Meetup Groups: December 2015



# IBM Announces Major Commitment to Advance Apache®Spark™, Calling it Potentially the Most Significant Open Source Project of the Next Decade

IBM Joins Spark Community, Plans

IBMはApache Spark の高度化へのコミットメントをアナウンス、次の10年で最も重要なオープンソースプロジェクトとなる可能性を秘めているという

ARMONK, NY - 15 Jun 2015: IBM ([NYSE:IBM](#)) announced its commitment to Apache®Spark™, potentially the most important open source project of the next decade. IBM is defining the future of business by data. At the core of this is the company's leadership in Analytics and Commerce platforms. IBM will also put more than 3,500 IBM researchers at more than a dozen labs worldwide; dedicating technology to the Spark open source ecosystem and scientists and data engineers on Spark.



Apache Spark popularity spike  
Apache Spark has overtaken Hadoop as the most active open source Big Data project. While they are not directly competing, they both have many of the same use cases.

VW staff, supplier warned of emissions test cheating years ago

Oil prices fall on slowing global economic growth outlook

India's Modi grew emotional at Facebook as he recalls his childhood

September jobs, Congress' deadline, and Trevor Noah — 5 things to know this week

ISIS has a money problem

Indian Prime Minister tours Tesla factory, talks batteries & solar with Elon Musk

How CST Brands' Kim Lulub is dealing with her biggest fear

Here's how Bono and Mark Zuckerberg aim to bring the Internet to the globe

Why Apple's Tim Cook sits at the

JUN 22, 2015 @ 10:28 AM 30,975 VIEWS

## Spark Or Hadoop -- Which Is The Best Big Data Framework?



One question about big data frameworks? Spark has overtaken Hadoop as the most active open source Big Data project. While they are not directly competing, they both have many of the same use cases.

**Spark Or Hadoop — どちらがベストなビッグデータフレームワーク？**

This article explaining the essential differences between the two frameworks tried to keep it accessible to everyone.

Apache Hadoop is one of the most popular tools used for processing large amounts of data.

TECH BIG DATA

## Survey shows huge popularity spike for Apache Spark

Apache Spark が人気急上昇だと

調査結果が示す



Click to go back, hold to see his

“Spark is the Taylor Swift  
of big data software.”

- Derrick Harris, Fortune

「Spark はビッグデータソフトウェアの  
テイラー・スウィフト※だ」

- ダーリック・ハリス、フォーチュン

※ 訳注：日本ではテレビ番組「テラスハウス」の主題歌などで有名



“Spark is the 北川景子  
of big data software.”

(A Japanese engineer told me)



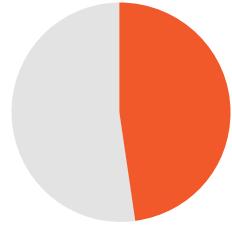


How are people using Spark?

# Diverse Runtime Environments

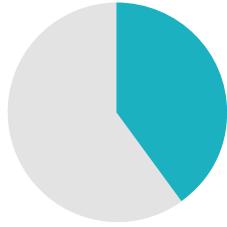
さまざまな実行環境

Cluster Managers



**48%**

Standalone mode



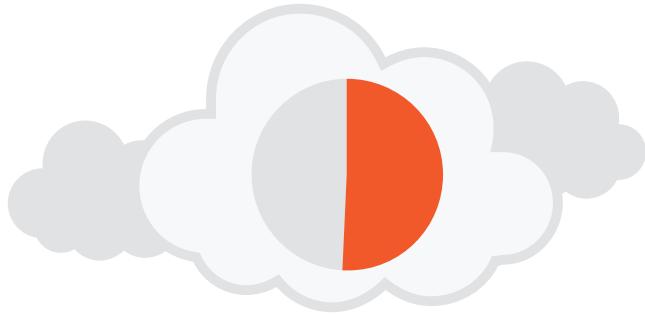
**40%**

YARN



**11%**

Mesos

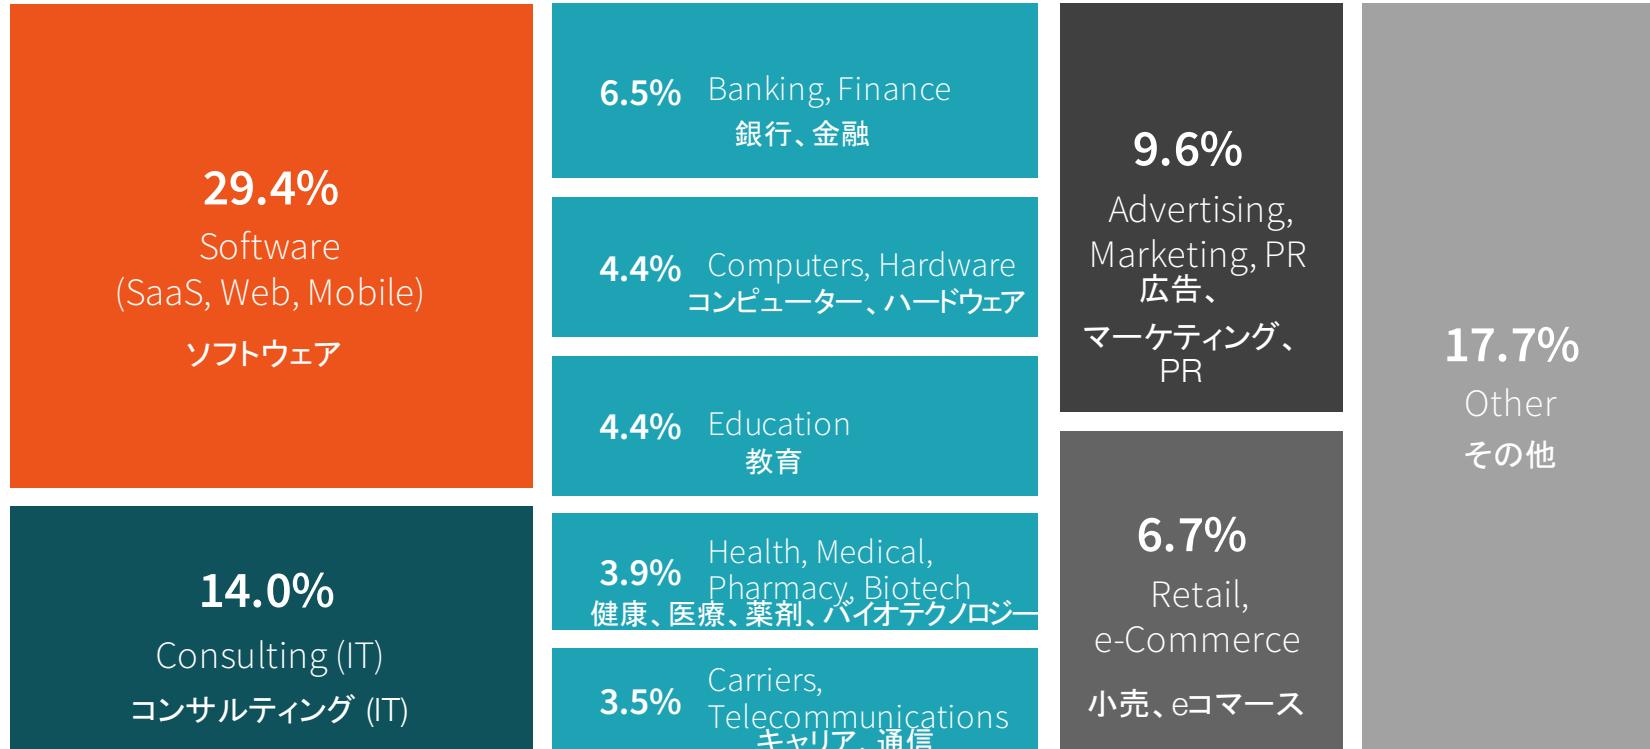


**51%**

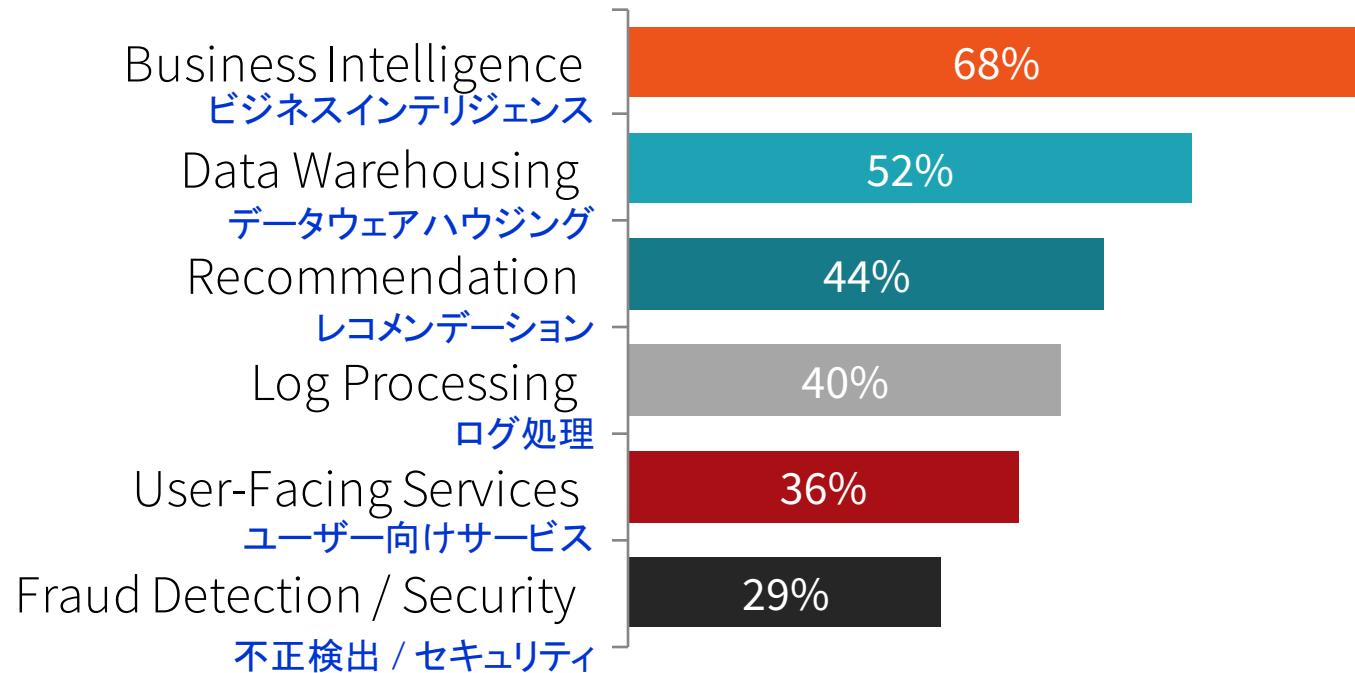
on a public cloud

# Industries Using Spark

## Sparkを利用している業界



# Top Applications 上位のアプリケーション

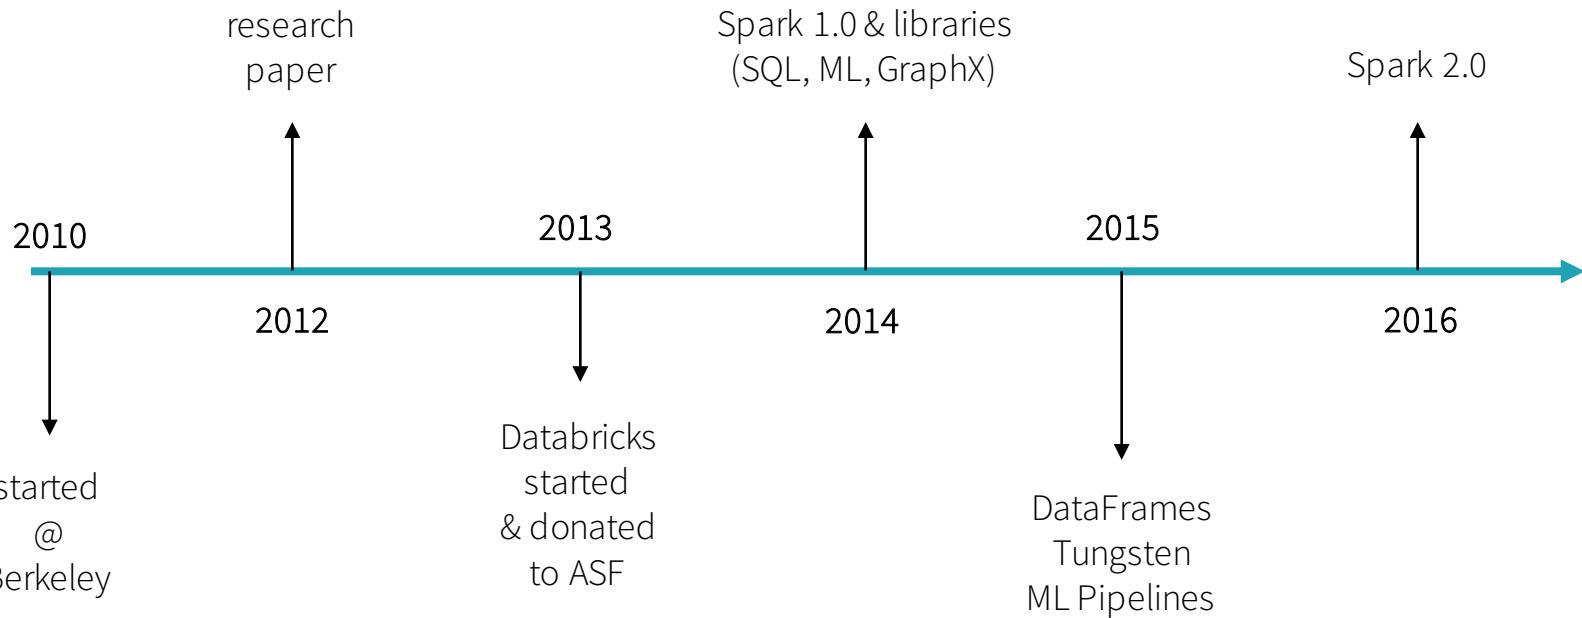


Are we done?

もう完成？

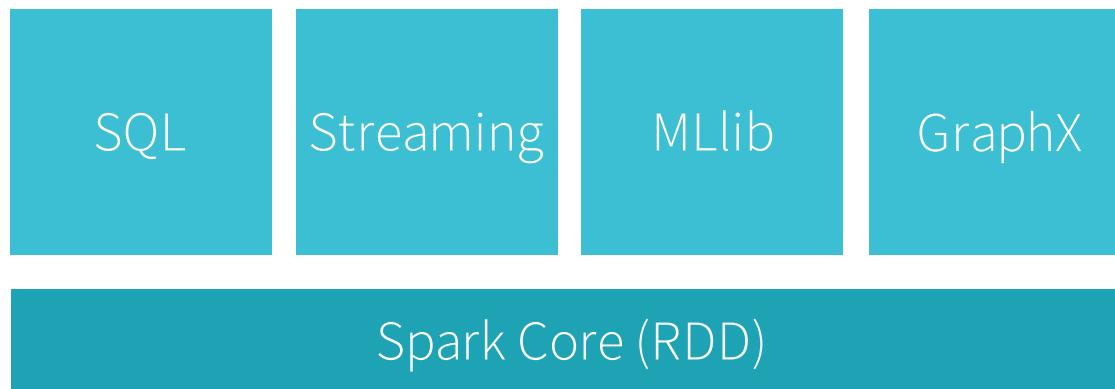
No. Development is faster than ever!

いいえ。開発は今まで以上に活発になって続いている！



# Spark stack diagram

Sparkのスタック図



# Spark stack diagram (a different take)

Sparkのスタック図  
(違う見方で)

Frontend  
(user facing APIs)

フロントエンド  
(ユーザーに面する  
API)

Backend  
(execution)

バックエンド  
(実行)

# Spark stack diagram (a different take)

Sparkのスタック図  
(違う見方で)

Frontend  
(RDD, DataFrame, ML pipelines, ...)

フロントエンド  
(RDD, DataFrame,  
ML pipelines, ...)

Backend  
(scheduler, shuffle, operators, ...)

バックエンド  
(スケジューラ、  
シャッフル、演算子、  
...)

# Spark 2.0

Frontend  
API Foundation  
**フロントエンド API の創設**

Streaming  
DataFrame/Dataset  
SQL  
**ストリーミング**  
DataFrame/Dataset  
SQL

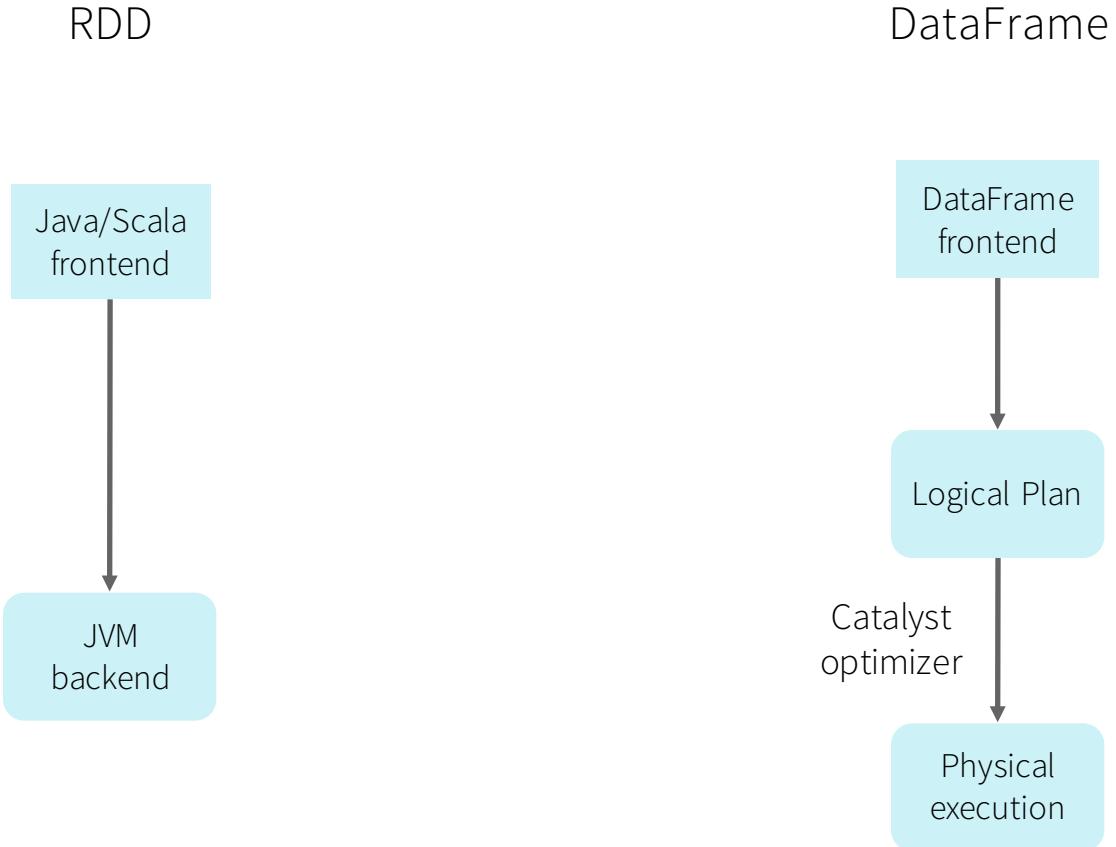
Backend  
10X Performance  
**バックエンド 10倍のパフォーマンス**

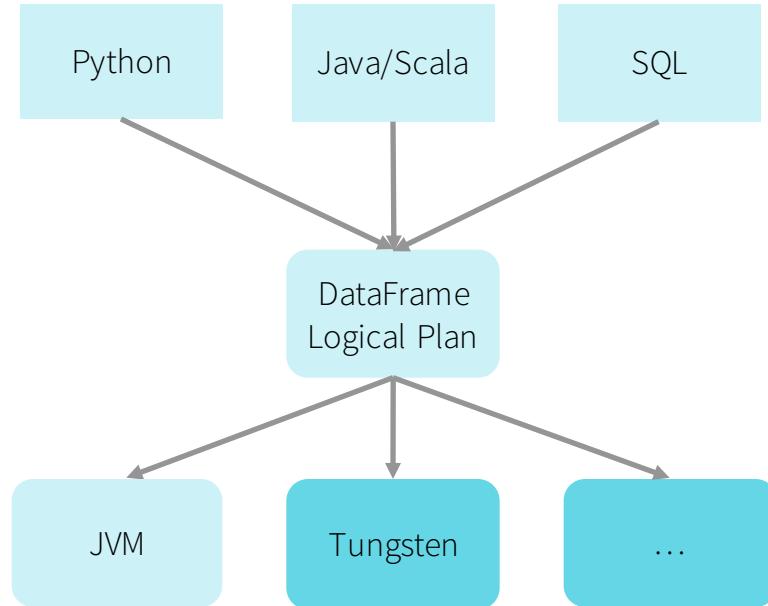
Whole-stage Codegen  
Vectorization  
**全ステージ コード生成**  
**ベクトル化**

# Guiding Principles for API Foundation

## API を創るにあたっての指針

1. Simple yet expressive  
シンプルだが表現豊かに
2. (Semantics) well-defined  
(セマンティクスが) 十分定義されている
3. Sufficiently abstracted to allow optimized backends  
バックエンドの最適化ができるよう十分に抽象化されている





# API Foundations in Spark 2.0

## Spark 2.0 における API の創設

### 1. Streaming DataFrames

ストリーミング DataFrame

### 2. Maturing and merging DataFrame and Dataset

DataFrame と Dataset の成熟とマージ

### 3. ANSI SQL

- natural join, subquery, view support

自然結合、サブクエリ、ビューのサポート

# Challenges with Stream Processing

## ストリーム処理に関する課題

Stream processing is hard to reason about

- Output overtime      **ストリーム処理が難しい理由は**
  - ・長い期間に渡るアウトプット
- Late data
  - ・遅れてくるデータ
- Failures
  - ・障害
- Distribution
  - ・分散

And all this has to work across complex operations

- Windows, sessions, aggregation, etc  
**これらすべてが複雑なオペレーションにわたって機能しなければならない**
  - ・ウインドウ、セッション、アグリゲーション、など

# Next-gen Streaming with DataFrames

## DataFramesによる次世代ストリーミング

1. Easy-to-use APIs (batch, streaming, and interactive)
  1. 使いやすいAPI (バッチ、ストリーミング、インタラクティブ)
2. Well-defined semantics
  - Out-of-order data
  - Failures
  - Sources/sinks with exactly-once semantics
  2. うまく定義されたセマンティクス
    - ・順序通りでないデータ
    - ・障害
    - ・exactly-once セマンティクスを持つ source / sink
3. Leverages Tungsten backend
  3. Tungsten バックエンドの利用

# Next-gen Streaming with DataFrames

## DataFramesによる次世代ストリーミング

1. Easy-to-use APIs (batch, streaming, and interactive)

1. 使いやすいAPI (バッチ、ストリーミング、インタラクティブ)

2. Well-defined semantics      2. うまく定義されたセマンティクス

More details next few weeks

- Out-of-order data

- Failures

- Sources/sinks with exactly-once semantics

数週間後により詳細を

• exactly-once セマンティクスを持つ source / sink

3. Leverages Tungsten backend

3. Tungsten バックエンドの利用

Spark is already pretty fast.

Spark はすでにかなり速い

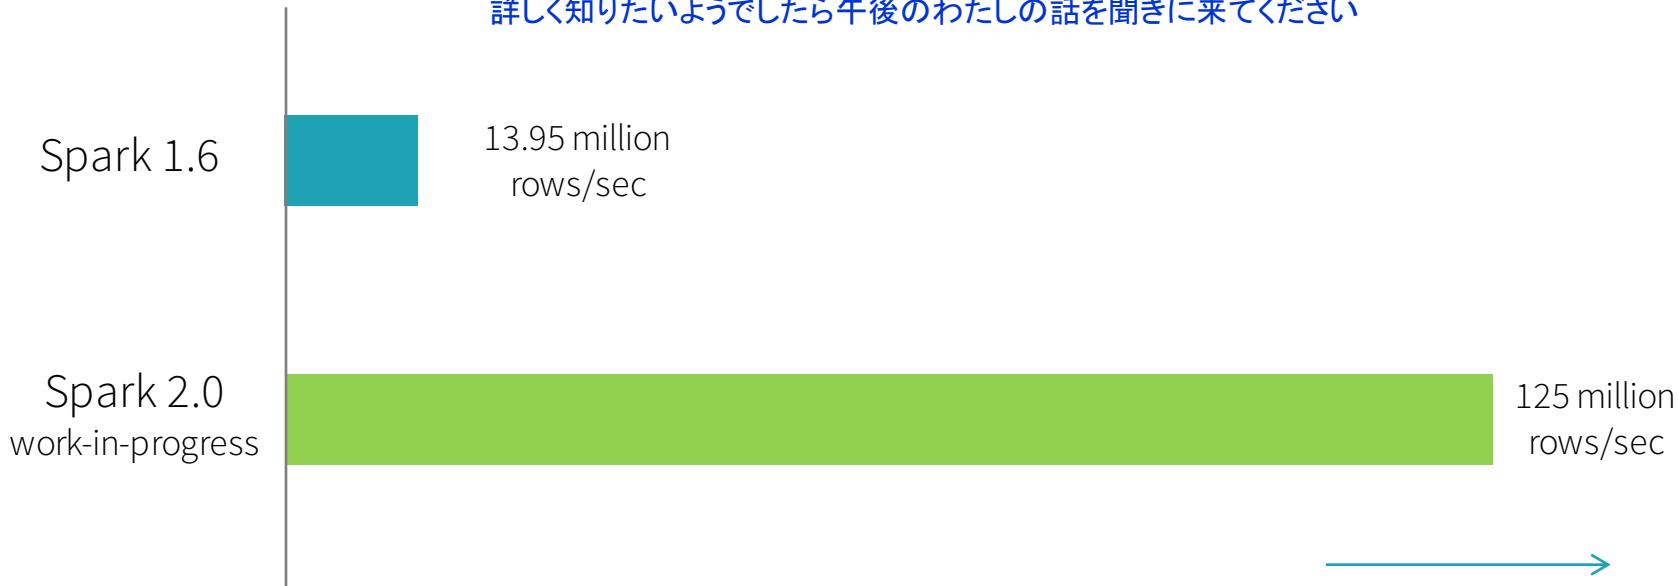
Can we make it 10X faster in 2.0?

2.0 で 10 倍高速にできるのだろうか？

# Teaser: SQL/DataFrame Performance

## 少しだけ宣伝: SQL/DataFrame のパフォーマンス

come to my talk this afternoon to learn more  
詳しく知りたいようでしたら午後のわたしの話を聞きに来てください



SQL

Python

R

Streaming

Advanced  
Analytics

DataFrame (& Dataset)

Tungsten Execution

# Spark 2.0 Release Schedule

## Spark 2.0 のリリーススケジュール

Under active development on GitHub

GitHub 上で活発に開発中

March – April: code freeze

3月-4月 : コードフリー<sup>ズ</sup>

April – May: official release

4月-5月 : 正式リリース

# ありがとうございました

@rxin

